

Adversarial Attack 결과 보고서

1. 베이스 모델

- MNIST: CNN
 - 2개의 합성곱 레이어(32, 64 채널)와 Max Pooling, Dropout으로 구성되며, 최종적으로 완전 연결 레이어를 통해 Log-Softmax로 클래스를 분류하는 CNN 기반 Classifier로 MNIST train dataset에 학습시킴
- CIFAR-10: Pretrained ResNet-18 (Fine-tuned)
 - ImageNet으로 사전 학습된 ResNet-18을 CIFAR-10에 맞게 Backbone 전체 파라미터에 대해 fine-tuning한 모델로, 32x32에 입력에 적합하도록 첫 번째 합성곱 레이어의 kernel size와 stride를 축소하고 Max Pooling을 제거하였으며, 최종 분류기를 10개 클래스로 교체함

2. 평가 메트릭

- 공격에 대한 평가 수행 시, 기존에 모델이 오분류했던 데이터는 제외하고 유효 샘플에 대해서만 평가가 수행됨
- Targeted ASR
 - Target 공격에 대한 성공률로, 본래 Target을 True label로 가지고 있던 클래스는 제외한 유효 데이터 셋 중 본래 Target이 아니었던 클래스가 Target으로 분류된 데이터 비중으로 ASR을 계산함

$$ASR_{\text{targeted}} = \frac{\sum_{i=1}^N \mathbf{1}[f(x_i) = y_i \wedge y_i \neq y_{\text{target}} \wedge f(x_i^{\text{adv}}) = y_{\text{target}}]}{\sum_{i=1}^N \mathbf{1}[f(x_i) = y_i \wedge y_i \neq y_{\text{target}}]}$$

- Untargeted ASR
 - Untarget 공격에 대한 성공률로 전체 유효 데이터셋 중 다른 클래스로 분류한 데이터 비중으로 ASR을 계산함

$$ASR_{\text{untargeted}} = \frac{\sum_{i=1}^N \mathbf{1}[f(x_i) = y_i \wedge f(x_i^{\text{adv}}) \neq y_i]}{\sum_{i=1}^N \mathbf{1}[f(x_i) = y_i]}$$

- $f(\cdot)$: 분류 모델의 예측 함수
- x_i : 원본 입력 이미지
- x_i^{adv} : Adversarial 이미지
- y_i : 실제 클래스 (True label)
- y_{target} : 목표 클래스

3. 실험 결과


- 실험 방법
 - 각 공격 방법 별 Epsilon List [0.05, 0.1, 0.2, 0.3, 0.4, 0.5]로 ASR 확인
 - Target Attack의 경우, Target Class = 8 로 지정하여 실험 수행
 - PGD 실험 시, K = 40, Eps step = 0.01로 (Aleksandas Madry et al., 2017)과 동일하게 설정
- 전반적인 실험 결과

Table 1: Attack Success Rate (%)

Dataset	ϵ	Targeted		Untargeted	
		FGSM	PGD	FGSM	PGD
MNIST	0.05	0.28	0.38	2.49	3.31
	0.10	1.65	4.84	8.94	21.85
	0.20	13.98	90.05	42.73	98.41
	0.30	36.58	100.00	81.32	100.00
	0.40	36.55	100.00	92.86	100.00
	0.50	31.14	100.00	92.80	100.00
CIFAR-10	0.05	22.89	93.10	83.52	99.67
	0.10	27.86	99.92	91.91	100.00
	0.20	21.32	100.00	93.35	100.00
	0.30	12.07	100.00	92.29	100.00
	0.40	4.10	100.00	91.14	100.00
	0.50	1.16	100.00	90.77	100.00

- 전반적으로 PGD는 FGSM보다 Target/Untarget 여부와 관계없이 훨씬 높은 공격 성공률을 보였음. 특히 MNIST targeted에서 $\epsilon = 0.2$ 일 때 PGD의 ASR은 90.05%로, 동일 조건에서 FGSM(13.98%) 대비 약 76%p 높은 성능 차이를 확인함.
- 또한, ϵ 이 약 0.3 이하일 때 CIFAR-10의 공격 성공률이 MNIST보다 상대적으로 높게 나타났는데, 이는 두 데이터셋에서 사용한 모델 차이에 기인한 결과로 예상됨.
- CIFAR-10이 MNIST보다 훨씬 복잡함에도 유효 공격이 더 많이 관찰된 이유로는 모델의 깊이와 복잡도가 영향을 미치는 것으로 예상됨. 예를 들어, ResNet-18은 MNIST용 CNN보다 더 깊은 residual 구조를 가져 Gradient가 입력까지 더 잘 전달될 수 있는 반면, CNN은 레이어가 상대적으로 얇아 입력에 대한 Gradient 신호가 약해 효과적인 공격으로 이어지지 못했을 가능성이 있음.
- 또한 ResNet-18은 ImageNet으로 사전 학습된 모델로, CNN보다 풍부한 feature representation을 갖고 있어 입력 공간에서 결정 경계가 더 민감하게 형성되어 있을 수 있음.
- 한 단계로 수행되는 FGSM의 전반적인 성능 관련하여, $\epsilon = 0.3$ 이내에서 Target/Untarget 모두 최고 성능을 보인 뒤 ASR이 감소하는 경향을 확인할 수 있었음. Targeted의 경우, 노이즈가 과도해져 오히려 해당 타겟으로의 예측을 방해했을 가능성이 있음.
- PGD는 MNIST에서 $\epsilon = 0.2$ 이후 ASR이 90%를 넘었고, ϵ 이 커질수록 100% 또는 그에 근접한 성능을 보였음. 다만 소요 시간 비교 시, CIFAR-10에서 PGD가 FGSM의 약 18배, MNIST에서 약 9배의 공격 시간이 소요되어, 비효율적인 모습을 보여줌.
 - 소요 시간: MNIST: FGSM - 0.3초, PGD - 2.6초 / CIFAR-10: FGSM - 1.9초, PGD - 39.0초)

- 데이터셋 클래스별 공격 난이도 평가



- 데이터셋 클래스별 공격 난이도를 비교하면, PGD는 클래스 편향 없이 전반적으로 균등한 공격 성공률을 보였으나 FGSM은 Target class에 따라 편차가 크게 나타남. 이는, 단일 Gradient 스텝 만으로는 클래스 간 결정 경계의 복잡도 차이를 극복하지 못하기 때문에 기인한 것으로 예상됨.
- 특히 MNIST에서는 라벨 2, 3에서 타겟 성공률이 높게 나타났는데, 이는 결정 경계가 유사한 클래스가 다른 단순한 구조를 가진 숫자(i.e. 0, 1)에 비해 많은 비중을 차지하여 나온 결과로 예상됨.
- CIFAR-10에서는 bird(2), deer(4), frog(6)의 FGSM 타겟 공격 성공률이 높았는데, 이 세 클래스의 공통점은 자연물로서 복잡한 형태의 자연 배경에 등장하는 경우가 많아 배경 픽셀이 클래스 결정에 큰 영향을 준 것으로 예상됨.

4. 회고

- 공격 성공률이 모델의 복잡도에 따라 증가할 것으로 예상했는데, 이를 위해 CNN 구조를 단계적으로 변형하거나, CIFAR-10에 사용한 ResNet-18을 MNIST에 적용하여 모델별 ASR을 비교하는 실험이 추가적으로 수행되면 본 내용을 뒷받침 할 수 있는 결과가 될 것이라고 생각함.
- PGD의 iteration 수 k 와 ϵ 스텝 사이즈를 다양하게 설정하여 공격 효율과 연산 비용 간의 trade-off를 분석하는 ablation study가 부족함.
- Target class 간 ASR의 큰 편차가 관찰되었는데, 이것이 클래스 간 시각적 유사도 때문인지, 모델의 결정 경계 형태 때문인지 본 실험에서는 원인 규명이 명확하게 되지 않아, 클래스 간 feature space 거리를 측정하거나, 결정 경계 시각화를 통해 편차의 원인을 분석하는 추가 실험이 필요함.