

Assignment#2 - Problem 2 (Essay)

이전에 구현한 FGSM(Fast Gradient Sign Method)과 PGD(Projected Gradient Descent)는 임의의 가중치와 Input의 Loss를 활용하여 모델을 속이기 위한 Perturbation 생성 공격 기법이다. 반면 DeepXplore는 여러 모델 간의 disagreement을 유도하는 입력을 탐색하여 모델의 취약점을 찾아내는 프레임워크이다. 두 방법론 모두 신경망의 약점을 드러내는 공통 목표를 가지고 있다.

- **DeepXplore 실험 결과 (CIFAR-10, ResNet50 모델 2개 비교)**

본 실험에서 다르게 랜덤 초기화된 ResNet-50 모델 2개로 Optimizer(SGD, AdamW)와 Image Augmentation을 다르게 하여 CIFAR-10 데이터셋에 대해 학습을 진행하였으며 Test Accuracy 에서 Model A 74.66%, Model B 84.75%로 약 10%의 성능 차이가 확인되었다. 이는 서로 다른 랜덤 초기화와 Optimizer로 인해 다른 결정 경계를 학습했기 때문이다. 특히 성능이 낮은 Model A는 더 넓은 불확실 영역을 가지며, 이로 인해 gradient descent 없이도 이미 많은 입력에서 Model B가 정확하게 예측한 상태에서 Model A의 성능 한계로 인해 disagreement가 자연적으로 발생했다. 따라서, differential testing의 의미 있는 결과를 얻으려면 두 모델의 성능이 비슷한 상태에서 테스트를 진행해야 한다.

- **Synergies**

FGSM이나 PGD를 활용하면 이미지를 모델의 결정 경계 근처에 위치한 adversarial example로 변환시켜주기 때문에, 이를 DeepXplore의 Seed Input으로 활용하면 탐색 효율을 높일 수 있을 것으로 예상된다. 반대로 DeepXplore의 neuron coverage 지표를 공격으로 활용할 수 있을 것 같다. 반대로 DeepXplore의 neuron coverage 지표가 adversarial attack의 perturbation 타겟 선택을 가이드로 활용할 수 있을 것으로 보이며, 아직 활성화되지 않은 뉴런을 타겟으로 perturbation을 생성하면 모델의 더 다양한 동작 영역을 탐색할 수 있을 것으로 예측된다.

- **Coverage-guided attacks**

Gradient 기반 공격인 FGSM/PGD의 목표를 neuron coverage 최대화로 전환하거나 두 목표를 동시에 추구하도록 수정할 수 있을 것으로 보인다. 예를 들어, PGD의 loss function에 neuron coverage 항을 추가하여 단순히 모델을 속이는 것을 넘어 더 넓은 결정 경계 영역을 탐색하도록 새로운 접근법으로 활용할 수 있을 것으로 예측된다.

- **Efficiency**

FGSM은 single-step으로 adversarial example을 생성하므로 DeepXplore의 gradient ascent 초기값으로 활용하면 수렴 속도를 높일 수 있다. 본 실험에서 grad_iterations를 50으로 설정했을 때도 일부 seed에서 disagreement을 찾지 못했는데, adversarial example을 초기값으로 사용하면 이러한 경우를 줄일 수 있을 것이다. 단, 본 실험처럼 두 모델 간 성능 차이가 클 경우 이미 많은 disagreement가 발생하므로, 결합의 효율은 두 모델의 성능이 유사할 때 보다 정확하게 파악할 수 있을 것으로 예상된다.

- **Limitations**

Adversarial example은 특정 모델을 속이도록 최적화된 입력이므로 다른 모델에서는 효과가 없는 transferability 문제가 발생할 수 있다. 또한 본 실험에서 확인했듯이 두 모델의 성능 차이가 크면 disagreement의 원인이 모델의 구조적 취약점이 아닌 단순한 성능 격차일 수 있어 테스트 결과의 신뢰성이 낮아지는 문제가 발생한다. 또한, neuron coverage를 활용하는 경우 계산 비용이 크게 증가하여 실시간 시스템에서는 적용이 어려울 수 있다.