

Assignment 4: α, β -Crown을 이용한 신경망 검증

1. 모델, 데이터셋, 검증 속성

1-1. 모델

Assignment 3 (Marabou)에서 사용한 동일한 EMNIST Letters FC 네트워크를 재사용함

항목	내용
구조	784 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 26 (완전연결, ReLU)
테스트 정확도	~90.64%
포맷	ONNX opset 11

1-2. 데이터셋

Marabou 방법론과 실험 결과 비교를 위해, 지난 Assignment #3 에서 사용한 알파벳 손글씨 데이터셋인 EMNIST Letters을 테스트 데이터셋으로 활용함

- 26개 클래스 (a-z), 클래스당 10개 샘플 = 총 **260개** 검증 인스턴스
- 정규화: mean = 0.1736, std = 0.3317

1-3. 검증 속성

지역 L^∞ 로버스트니스 ($\epsilon = 0.01$)

$$\forall x' : \|x' - x\|_\infty \leq 0.01 \implies \arg \max f(x') = c$$

샘플 x 가 클래스 c 로 분류될 때, L^∞ 볼 내부의 모든 입력도 동일하게 c 로 분류되는지 검증함.

이를 **VNNlib DNF (Disjunctive Normal Form)** 형식으로 인코딩하며, 속성의 **부정(negation)** 을 질의하므로 다음과 같이 검증 결과를 해석할 수 있음

① 검증 결과 해석

- unsat $\rightarrow$ 반례 없음 $\rightarrow$ 검증됨 (**Verified**)
- sat $\rightarrow$ 반례 발견 $\rightarrow$ 위반됨 (**Falsified**)
- timeout $\rightarrow$ 시간 초과 $\rightarrow$ 미결정

```
(assert (or
  (and (>= Y_1 Y_0)) ; 클래스 1이 정답 클래스 0을 이길 수 있는가?
  (and (>= Y_2 Y_0))
  ...
  (and (>= Y_25 Y_0))
))
```

2. 실험 결과


2-1. 검증 결과 요약

지표	α, β -Crown	Marabou (Assignment 3)
총 인스턴스	260	260
Verified	233 (89.6%)	230 (88.5%)
Falsified	27 (10.4%)	30 (11.5%)
Timeout	0 (0.0%)	0 (0.0%)
총 소요 시간	~45초 (CPU)	~35분 (추정)
인스턴스당 평균 시간	~0.28s	~4.0s (UNSAT) / ~2.5s (SAT)
중앙값 속도 향상	356x	—
Marabou 결과 일치율	100% (260/260)	—

⚠ CPU 실행 참고

α, β -Crown은 torch 2.11.0+cu130 빌드이나, 시스템 CUDA 드라이버가 12.2(535.x)로 cu130 미지원. 이번 실험은 **CPU** 전용으로 수행. GPU 사용 시 추가 속도 향상 기대 가능.


2-2.글자별 결과 (Figure 1)



'i'가 10개 중 6개 Falsified로 가장 취약한 클래스로 나타났으며 이는, 'l', 'j' 등 세로선 형태의 글자와 시각적으로 유사하여 모델의 결정 경계가 불안정하기 때문인 것으로 예측됨. Assignment 3 (Marabou)에서도 동일하게 'i'가 가장 취약한 결과를 보여주었음.

2-3.속도 비교 (Figure 2)

Verification Time: Marabou vs α, β -Crown (per sample, 260 instances)




- 왼쪽 (로그-로그 산점도): 모든 점이 $y = x$ 선 아래에 위치 → α, β -Crown이 항상 더 빠름
- 오른쪽 (속도 향상 히스토그램): 대부분의 샘플에서 1000× 이상의 향상을 보임

☞ 극단적 사례

Marabou가 115초 걸린 샘플에서 α, β -Crown은 **0.03초** (PGD 공격)로 반례를 즉시 발견.


2-4. 시간 분포 (Figure 3)

Verification Time Distributions ($\epsilon = 0.01$, 260 samples)



- α, β -Crown: 260개 전부가 0 ~ 0.35초 내 완료
- Marabou: 2 ~ 6초에 분산

2-5. 결과 일치 (Figure 4)



260개 전체에서 두 툴의 결과가 완전히 일치한다.

	α, β -Crown: Verified	α, β -Crown: Falsified
Marabou: Verified	233	0
Marabou: Falsified	0	27

완전히 다른 알고리즘임에도 100% 일치 → 두 툴 모두 수학적으로 건전(sound) 하게 구현됨을 의미함.

3. α,β -Crown vs Marabou 비교

알고리즘 비교

측면	Marabou	α,β -Crown
핵심 방법	SMT/LP 솔버 (symbolic)	Bound propagation + BaB (numeric)
SAT 탐지	LP 탐색 공간 열거	PGD 적대적 공격 (gradient 기반)
UNSAT 증명	SMT 반박	선형 완화(CROWN) 경계 계산
속성 인코딩	25개 별도 LP 쿼리	1개 DNF 쿼리 (전체 클래스 동시)
GPU 지원	✗	✓ (CUDA)
입력 포맷	Python API / ONNX	YAML + VNNlib (표준화)

속도

α,β -Crown이 중앙값 기준 **356배** 빠른 검증 시간을 보여주었는데, 이는 하기 두 가지 요인에서 기인함.

- PGD 우선 공격:** Falsified 케이스(27개)의 경우, PGD가 평균 0.03~0.05초 안에 반례를 발견. Marabou는 동일 케이스에 평균 2.5초 소요.
- 단일 쿼리 처리:** Marabou는 26클래스에 대해 25개 LP 서브쿼리를 순차 실행하는 반면, α,β -Crown은 DNF로 모든 클래스를 한 번에 처리.

확장성

두 툴 모두 이 작은 FC 네트워크에서는 문제없이 동작함. 더 큰 네트워크(ResNet, Transformer 등)에서는 α,β -Crown의 GPU 병렬 BaB가 Marabou의 SMT 솔버보다 훨씬 유리할 것으로 예상됨. Marabou의 SMT 솔버는 최악의 경우 지수적으로 확장되는 문제가 존재함.

사용 편의성

- Marabou:** Python API가 직관적. 프로그래밍 방식으로 제약 조건 추가가 쉬움. 소규모 실험에 적합.
- α,β -Crown:** YAML 설정 + VNNlib 스펙 파일 작성이 필요하여 초기 설정 비용이 높음. 단, VNNlib은 표준화된 포맷으로 다른 검증 툴과도 호환됨 (VNN-COMP 벤치마크).

4. α,β -Crown의 강점과 한계

강점

✓ α,β -Crown 강점

- 속도:** GPU 가속 bound propagation으로 SMT 기반 대비 수백~수천 배 빠름
- 타이트한 경계:** CROWN/LiRPA가 단순 구간 산술보다 타이트한 선형 완화를 계산 → 구간 산술로 증명 불가능한 케이스도 검증 가능
- 유연성:** L^∞ , L2, L1 노름 지원; 합성곱, 잔차 연결, 트랜스포머 구조 지원; VNNlib으로 커스텀 속성 정의 가능
- 실적:** VNN-COMP 2021~2025 우승, 실용적 성능 입증

한계

⚠ 이번 실험에서 관찰된 한계

- 설치 복잡성: conda 환경, auto_LiRPA, onnx2pytorch, gurobipy 등 의존성 관리가 복잡. CUDA 드라이버 12.2가 cu130 PyTorch 빌드와 호환되지 않아 CPU 전용으로 실행.
- **VNNlib** 형식 제약: 속성을 DNF 형식 (`and (>= Y_j Y_c)`) 으로 정확히 기술해야 하며, Marabou의 Python API보다 인코딩이 까다로움.
- **PGD** 반례의 한계: Falsified 케이스의 반례는 PGD(gradient 기반)로 발견되므로 최소 노름 perturbation이 아닐 수 있음. Marabou의 LP 솔버는 정확한 반례를 반환.